

Rapport analyse 3 (devoir)

Marie Simone DJIBOUNE

2026-01-11

#Chargement des librairies

```
library(readxl)
library(ggplot2)
library(dplyr)

library(reshape2)

library(vcd)
```

#Chargement de la base de donnee

```
df = read_excel(file.choose())
```

#structure de la BD

```
str(df)

## tibble [144 × 24] (S3: tbl_df/tbl/data.frame)
##  $ Obs_ID          : num [1:144] 1 2 3 4 5 6 7 8 9 10 ...
##  $ Station         : chr [1:144] "ST01" "ST02" "ST03" "ST04" ...
##  $ Localite        : chr [1:144] "Thiès Nord" "Thiès Est" "Thiès Ouest"
##  " Médina Fall" ...
##  $ Type_zone       : chr [1:144] "Urbain" "Urbain" "Urbain" "Urbain" .
##  ..
##  $ Usage_sol       : chr [1:144] "Industriel" "Résidentiel" "Résidenti
##  el" "Mixte" ...
##  $ Risque_inondation : chr [1:144] "Faible" "Faible" "Moyen" "Faible" ..
##  .
##  $ Date            : POSIXct[1:144], format: "2025-01-01" "2025-01-01"
##  ...
##  $ Temperature_C   : num [1:144] NA 34.4 30.6 29.5 29.4 ...
##  $ Humidite_pct     : num [1:144] 53.5 NA 55.3 40.6 56 ...
##  $ Pluie_mm         : num [1:144] 8.07 1.87 2.68 8.58 2.98 ...
##  $ Vent_mps         : num [1:144] 3.87 1.89 2.82 2.55 2.66 ...
##  $ PM25_ugm3        : num [1:144] 62.7 43.8 NA 40.6 65.2 ...
##  $ NO2_ppb          : num [1:144] 36.1 25.1 20.6 27.9 27.6 ...
##  $ Bruit_dB         : num [1:144] 78.2 63.6 67.9 68.1 63.2 ...
##  $ NDVI             : num [1:144] 0.12 0.314 0.153 0.224 0.365 ...
##  $ Perception_air_1a5 : num [1:144] 3 4 4 4 3 4 3 4 NA 4 ...
##  $ Gene_bruit_1a5    : num [1:144] 4 2 3 4 NA 3 2 2 NA 1 ...
##  $ Qualite_capteur   : chr [1:144] NA "Bon" "Bon" "Moyen" ...
##  $ Brulage_dechets   : chr [1:144] NA "Non" "Non" NA ...
```


[illegible]

[illegible]

## [136,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [137,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [138,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [139,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [140,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [141,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [142,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [143,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
## [144,]	FALSE	FALSE	FALSE	FALSE	FALSE		FALSE	FALSE
##	Temperature_C	Humidite_pct	Pluie_mm	Vent_mps	PM25_ugm3	N02_ppb	Bruit	
t_dB								
## [1,]		TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [2,]		FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [3,]		FALSE	FALSE	FALSE	FALSE	TRUE	FALSE	F
ELSE								
## [4,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [5,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [6,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [7,]		FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [8,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [9,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE								
## [10,]		FALSE	FALSE	FALSE	TRUE	TRUE	FALSE	F
ELSE								
## [11,]		FALSE	FALSE	FALSE	TRUE	FALSE	TRUE	F
ELSE								
## [12,]		FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ELSE								
## [13,]		TRUE	FALSE	FALSE	FALSE	TRUE	FALSE	
TRUE								
## [14,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [15,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [16,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [17,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [18,]		TRUE	FALSE	FALSE	FALSE	TRUE	FALSE	F
ELSE								
## [19,]		FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ELSE								
## [20,]		FALSE	FALSE	FALSE	FALSE	TRUE	FALSE	F

ALSE							
## [21,]	FALSE	FALSE	TRUE	FALSE	TRUE	FALSE	F
ALSE							
## [22,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [23,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [24,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [25,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [26,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [27,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [28,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [29,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [30,]	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [31,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [32,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [33,]	FALSE	TRUE	TRUE	FALSE	TRUE	FALSE	F
ALSE							
## [34,]	FALSE	FALSE	TRUE	TRUE	FALSE	FALSE	F
ALSE							
## [35,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [36,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [37,]	FALSE	FALSE	TRUE	TRUE	FALSE	FALSE	F
ALSE							
## [38,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [39,]	FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [40,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [41,]	FALSE	TRUE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [42,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [43,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [44,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [45,]	FALSE	FALSE	TRUE	FALSE	FALSE	FALSE	F

ALSE							
## [46,]	TRUE	FALSE	FALSE	FALSE	TRUE	FALSE	
TRUE							
## [47,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [48,]	FALSE	TRUE	TRUE	FALSE	FALSE	FALSE	F
ALSE							
## [49,]	FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [50,]	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [51,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [52,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [53,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [54,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [55,]	FALSE	FALSE	TRUE	FALSE	TRUE	TRUE	F
ALSE							
## [56,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [57,]	FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [58,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [59,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [60,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [61,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [62,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [63,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [64,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [65,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [66,]	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [67,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [68,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [69,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	
TRUE							
## [70,]	FALSE	TRUE	TRUE	FALSE	FALSE	TRUE	F

ALSE							
## [71,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [72,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [73,]	FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [74,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [75,]	FALSE	TRUE	TRUE	TRUE	TRUE	FALSE	F
ALSE							
## [76,]	FALSE	FALSE	TRUE	FALSE	FALSE	FALSE	F
ALSE							
## [77,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [78,]	FALSE	FALSE	FALSE	FALSE	TRUE	FALSE	F
ALSE							
## [79,]	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [80,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [81,]	FALSE	FALSE	TRUE	FALSE	FALSE	FALSE	F
ALSE							
## [82,]	FALSE	FALSE	FALSE	FALSE	TRUE	FALSE	
TRUE							
## [83,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [84,]	FALSE	FALSE	TRUE	FALSE	FALSE	FALSE	F
ALSE							
## [85,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [86,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [87,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [88,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [89,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [90,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [91,]	FALSE	FALSE	TRUE	FALSE	FALSE	TRUE	F
ALSE							
## [92,]	FALSE	FALSE	FALSE	FALSE	TRUE	TRUE	F
ALSE							
## [93,]	TRUE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [94,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [95,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F

ALSE							
## [96,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [97,]	TRUE	FALSE	FALSE	FALSE	TRUE	FALSE	F
ALSE							
## [98,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [99,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [100,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [101,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [102,]	FALSE	TRUE	FALSE	FALSE	TRUE	FALSE	F
ALSE							
## [103,]	FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [104,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [105,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [106,]	TRUE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [107,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [108,]	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [109,]	FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [110,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [111,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [112,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [113,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [114,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [115,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [116,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [117,]	FALSE	FALSE	FALSE	TRUE	FALSE	TRUE	F
ALSE							
## [118,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [119,]	TRUE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [120,]	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	F

ALSE							
## [121,]	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [122,]	FALSE	TRUE	TRUE	FALSE	FALSE	TRUE	F
ALSE							
## [123,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [124,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [125,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [126,]	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [127,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [128,]	FALSE	FALSE	TRUE	FALSE	FALSE	FALSE	F
ALSE							
## [129,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [130,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [131,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [132,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [133,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [134,]	FALSE	TRUE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [135,]	FALSE	FALSE	FALSE	TRUE	FALSE	FALSE	F
ALSE							
## [136,]	FALSE	FALSE	FALSE	FALSE	TRUE	FALSE	F
ALSE							
## [137,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [138,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [139,]	FALSE	FALSE	FALSE	FALSE	TRUE	FALSE	F
ALSE							
## [140,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	F
ALSE							
## [141,]	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	
TRUE							
## [142,]	FALSE	FALSE	TRUE	FALSE	FALSE	FALSE	F
ALSE							
## [143,]	FALSE	FALSE	FALSE	FALSE	FALSE	TRUE	F
ALSE							
## [144,]	FALSE	FALSE	TRUE	TRUE	FALSE	FALSE	F
ALSE							
##	NDVI	Perception_air_1a5	Gene_bruit_1a5	Qualite_capteur	Brulage_dec		

hets					
## [1,] FALSE	FALSE	FALSE	TRUE		
TRUE					
## [2,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [3,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [4,] FALSE	FALSE	FALSE	FALSE		
TRUE					
## [5,] FALSE	FALSE	TRUE	FALSE		
TRUE					
## [6,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [7,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [8,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [9,] FALSE	TRUE	TRUE	TRUE	F	
ALSE					
## [10,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [11,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [12,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [13,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [14,] FALSE	FALSE	TRUE	FALSE		
TRUE					
## [15,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [16,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [17,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [18,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [19,] FALSE	FALSE	FALSE	TRUE	F	
ALSE					
## [20,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [21,] FALSE	FALSE	FALSE	TRUE	F	
ALSE					
## [22,] FALSE	FALSE	FALSE	FALSE	F	
ALSE					
## [23,] FALSE	TRUE	FALSE	FALSE	F	
ALSE					
## [24,] FALSE	TRUE	FALSE	TRUE	F	
ALSE					
## [25,] FALSE	FALSE	FALSE	FALSE	F	

ALSE				
## [26,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [27,] FALSE	TRUE	FALSE	FALSE	F
ALSE				
## [28,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [29,] TRUE	FALSE	FALSE	FALSE	F
ALSE				
## [30,] TRUE	FALSE	FALSE	FALSE	F
ALSE				
## [31,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [32,] TRUE	TRUE	FALSE	TRUE	F
ALSE				
## [33,] FALSE	TRUE	FALSE	FALSE	
TRUE				
## [34,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [35,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [36,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [37,] TRUE	FALSE	FALSE	TRUE	F
ALSE				
## [38,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [39,] FALSE	FALSE	FALSE	FALSE	
TRUE				
## [40,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [41,] TRUE	TRUE	FALSE	FALSE	
TRUE				
## [42,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [43,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [44,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [45,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [46,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [47,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [48,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [49,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [50,] TRUE	FALSE	FALSE	FALSE	

TRUE				
## [51,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [52,] FALSE	FALSE	FALSE	FALSE	
TRUE				
## [53,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [54,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [55,] FALSE	TRUE	FALSE	FALSE	F
ALSE				
## [56,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [57,] TRUE	TRUE	FALSE	FALSE	F
ALSE				
## [58,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [59,] FALSE	TRUE	FALSE	FALSE	F
ALSE				
## [60,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [61,] FALSE	TRUE	FALSE	FALSE	F
ALSE				
## [62,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [63,] TRUE	FALSE	FALSE	FALSE	
TRUE				
## [64,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [65,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [66,] FALSE	FALSE	FALSE	TRUE	F
ALSE				
## [67,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [68,] TRUE	FALSE	FALSE	FALSE	F
ALSE				
## [69,] FALSE	FALSE	FALSE	TRUE	F
ALSE				
## [70,] FALSE	FALSE	TRUE	TRUE	F
ALSE				
## [71,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [72,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [73,] TRUE	FALSE	FALSE	FALSE	F
ALSE				
## [74,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [75,] FALSE	FALSE	FALSE	FALSE	F

ALSE				
## [76,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [77,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [78,] FALSE	FALSE	FALSE	FALSE	
TRUE				
## [79,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [80,] FALSE	TRUE	FALSE	FALSE	F
ALSE				
## [81,] FALSE	FALSE	FALSE	TRUE	F
ALSE				
## [82,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [83,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [84,] FALSE	FALSE	FALSE	TRUE	
TRUE				
## [85,] FALSE	FALSE	FALSE	FALSE	
TRUE				
## [86,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [87,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [88,] FALSE	TRUE	FALSE	FALSE	F
ALSE				
## [89,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [90,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [91,] FALSE	TRUE	FALSE	TRUE	F
ALSE				
## [92,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [93,] TRUE	FALSE	FALSE	FALSE	F
ALSE				
## [94,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [95,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [96,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [97,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [98,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [99,] FALSE	FALSE	FALSE	FALSE	
TRUE				
## [100,] FALSE	FALSE	FALSE	FALSE	F

ALSE				
## [101,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [102,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [103,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [104,] FALSE	FALSE	FALSE	FALSE	
TRUE				
## [105,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [106,] FALSE	FALSE	FALSE	TRUE	F
ALSE				
## [107,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [108,] TRUE	FALSE	FALSE	FALSE	F
ALSE				
## [109,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [110,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [111,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [112,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [113,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [114,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [115,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [116,] FALSE	TRUE	TRUE	FALSE	F
ALSE				
## [117,] TRUE	FALSE	FALSE	FALSE	F
ALSE				
## [118,] FALSE	FALSE	FALSE	TRUE	F
ALSE				
## [119,] FALSE	FALSE	FALSE	FALSE	
TRUE				
## [120,] TRUE	TRUE	FALSE	FALSE	F
ALSE				
## [121,] FALSE	FALSE	FALSE	FALSE	F
ALSE				
## [122,] FALSE	FALSE	FALSE	TRUE	F
ALSE				
## [123,] FALSE	FALSE	TRUE	FALSE	F
ALSE				
## [124,] FALSE	TRUE	FALSE	FALSE	F
ALSE				
## [125,] FALSE	FALSE	FALSE	FALSE	F

ALSE					
## [126,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [127,]	FALSE	FALSE	TRUE	FALSE	F
ALSE					
## [128,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [129,]	TRUE	FALSE	FALSE	FALSE	F
ALSE					
## [130,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [131,]	FALSE	FALSE	TRUE	TRUE	F
ALSE					
## [132,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [133,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [134,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [135,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [136,]	FALSE	FALSE	FALSE	FALSE	
TRUE					
## [137,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [138,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [139,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [140,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [141,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [142,]	FALSE	FALSE	FALSE	FALSE	F
ALSE					
## [143,]	TRUE	FALSE	FALSE	FALSE	F
ALSE					
## [144,]	TRUE	FALSE	TRUE	FALSE	F
ALSE					
##	Phase_intervention	Campagne	Agent_collecteur	Numero_serie_capteur	
## [1,]	TRUE	FALSE	FALSE	FALSE	
## [2,]	TRUE	FALSE	FALSE	FALSE	
## [3,]	TRUE	FALSE	FALSE	FALSE	
## [4,]	TRUE	FALSE	FALSE	FALSE	
## [5,]	TRUE	FALSE	FALSE	FALSE	
## [6,]	TRUE	FALSE	FALSE	FALSE	
## [7,]	TRUE	FALSE	FALSE	FALSE	
## [8,]	TRUE	FALSE	FALSE	FALSE	
## [9,]	TRUE	FALSE	FALSE	FALSE	
## [10,]	TRUE	FALSE	FALSE	FALSE	

##	[11,]	TRUE	FALSE	FALSE	FALSE
##	[12,]	TRUE	FALSE	FALSE	FALSE
##	[13,]	TRUE	FALSE	FALSE	FALSE
##	[14,]	TRUE	FALSE	FALSE	FALSE
##	[15,]	TRUE	FALSE	FALSE	FALSE
##	[16,]	TRUE	FALSE	FALSE	FALSE
##	[17,]	TRUE	FALSE	FALSE	FALSE
##	[18,]	TRUE	FALSE	FALSE	FALSE
##	[19,]	TRUE	FALSE	FALSE	FALSE
##	[20,]	TRUE	FALSE	FALSE	FALSE
##	[21,]	TRUE	FALSE	FALSE	FALSE
##	[22,]	TRUE	FALSE	FALSE	FALSE
##	[23,]	TRUE	FALSE	FALSE	FALSE
##	[24,]	TRUE	FALSE	FALSE	FALSE
##	[25,]	TRUE	FALSE	FALSE	FALSE
##	[26,]	TRUE	FALSE	FALSE	FALSE
##	[27,]	TRUE	FALSE	FALSE	FALSE
##	[28,]	TRUE	FALSE	FALSE	FALSE
##	[29,]	TRUE	FALSE	FALSE	FALSE
##	[30,]	TRUE	FALSE	FALSE	FALSE
##	[31,]	TRUE	FALSE	FALSE	FALSE
##	[32,]	TRUE	FALSE	FALSE	FALSE
##	[33,]	TRUE	FALSE	FALSE	FALSE
##	[34,]	TRUE	FALSE	FALSE	FALSE
##	[35,]	TRUE	FALSE	FALSE	FALSE
##	[36,]	TRUE	FALSE	FALSE	FALSE
##	[37,]	TRUE	FALSE	FALSE	FALSE
##	[38,]	TRUE	FALSE	FALSE	FALSE
##	[39,]	TRUE	FALSE	FALSE	FALSE
##	[40,]	TRUE	FALSE	FALSE	FALSE
##	[41,]	TRUE	FALSE	FALSE	FALSE
##	[42,]	TRUE	FALSE	FALSE	FALSE
##	[43,]	TRUE	FALSE	FALSE	FALSE
##	[44,]	TRUE	FALSE	FALSE	FALSE
##	[45,]	TRUE	FALSE	FALSE	FALSE
##	[46,]	TRUE	FALSE	FALSE	FALSE
##	[47,]	TRUE	FALSE	FALSE	FALSE
##	[48,]	TRUE	FALSE	FALSE	FALSE
##	[49,]	TRUE	FALSE	FALSE	FALSE
##	[50,]	TRUE	FALSE	FALSE	FALSE
##	[51,]	TRUE	FALSE	FALSE	FALSE
##	[52,]	TRUE	FALSE	FALSE	FALSE
##	[53,]	TRUE	FALSE	FALSE	FALSE
##	[54,]	TRUE	FALSE	FALSE	FALSE
##	[55,]	TRUE	FALSE	FALSE	FALSE
##	[56,]	TRUE	FALSE	FALSE	FALSE
##	[57,]	TRUE	FALSE	FALSE	FALSE
##	[58,]	TRUE	FALSE	FALSE	FALSE
##	[59,]	TRUE	FALSE	FALSE	FALSE
##	[60,]	TRUE	FALSE	FALSE	FALSE

##	[61,]	TRUE	FALSE	FALSE	FALSE
##	[62,]	TRUE	FALSE	FALSE	FALSE
##	[63,]	TRUE	FALSE	FALSE	FALSE
##	[64,]	TRUE	FALSE	FALSE	FALSE
##	[65,]	TRUE	FALSE	FALSE	FALSE
##	[66,]	TRUE	FALSE	FALSE	FALSE
##	[67,]	TRUE	FALSE	FALSE	FALSE
##	[68,]	TRUE	FALSE	FALSE	FALSE
##	[69,]	TRUE	FALSE	FALSE	FALSE
##	[70,]	TRUE	FALSE	FALSE	FALSE
##	[71,]	TRUE	FALSE	FALSE	FALSE
##	[72,]	TRUE	FALSE	FALSE	FALSE
##	[73,]	TRUE	FALSE	FALSE	FALSE
##	[74,]	TRUE	FALSE	FALSE	FALSE
##	[75,]	TRUE	FALSE	FALSE	FALSE
##	[76,]	TRUE	FALSE	FALSE	FALSE
##	[77,]	TRUE	FALSE	FALSE	FALSE
##	[78,]	TRUE	FALSE	FALSE	FALSE
##	[79,]	TRUE	FALSE	FALSE	FALSE
##	[80,]	TRUE	FALSE	FALSE	FALSE
##	[81,]	TRUE	FALSE	FALSE	FALSE
##	[82,]	TRUE	FALSE	FALSE	FALSE
##	[83,]	TRUE	FALSE	FALSE	FALSE
##	[84,]	TRUE	FALSE	FALSE	FALSE
##	[85,]	TRUE	FALSE	FALSE	FALSE
##	[86,]	TRUE	FALSE	FALSE	FALSE
##	[87,]	TRUE	FALSE	FALSE	FALSE
##	[88,]	TRUE	FALSE	FALSE	FALSE
##	[89,]	TRUE	FALSE	FALSE	FALSE
##	[90,]	TRUE	FALSE	FALSE	FALSE
##	[91,]	TRUE	FALSE	FALSE	FALSE
##	[92,]	TRUE	FALSE	FALSE	FALSE
##	[93,]	TRUE	FALSE	FALSE	FALSE
##	[94,]	TRUE	FALSE	FALSE	FALSE
##	[95,]	TRUE	FALSE	FALSE	FALSE
##	[96,]	TRUE	FALSE	FALSE	FALSE
##	[97,]	TRUE	FALSE	FALSE	FALSE
##	[98,]	TRUE	FALSE	FALSE	FALSE
##	[99,]	TRUE	FALSE	FALSE	FALSE
##	[100,]	TRUE	FALSE	FALSE	FALSE
##	[101,]	TRUE	FALSE	FALSE	FALSE
##	[102,]	TRUE	FALSE	FALSE	FALSE
##	[103,]	TRUE	FALSE	FALSE	FALSE
##	[104,]	TRUE	FALSE	FALSE	FALSE
##	[105,]	TRUE	FALSE	FALSE	FALSE
##	[106,]	TRUE	FALSE	FALSE	FALSE
##	[107,]	TRUE	FALSE	FALSE	FALSE
##	[108,]	TRUE	FALSE	FALSE	FALSE
##	[109,]	TRUE	FALSE	FALSE	FALSE
##	[110,]	TRUE	FALSE	FALSE	FALSE

## [111,]	TRUE	FALSE	FALSE	FALSE
## [112,]	TRUE	FALSE	FALSE	FALSE
## [113,]	TRUE	FALSE	FALSE	FALSE
## [114,]	TRUE	FALSE	FALSE	FALSE
## [115,]	TRUE	FALSE	FALSE	FALSE
## [116,]	TRUE	FALSE	FALSE	FALSE
## [117,]	TRUE	FALSE	FALSE	FALSE
## [118,]	TRUE	FALSE	FALSE	FALSE
## [119,]	TRUE	FALSE	FALSE	FALSE
## [120,]	TRUE	FALSE	FALSE	FALSE
## [121,]	FALSE	FALSE	FALSE	FALSE
## [122,]	FALSE	FALSE	FALSE	FALSE
## [123,]	FALSE	FALSE	FALSE	FALSE
## [124,]	FALSE	FALSE	FALSE	FALSE
## [125,]	FALSE	FALSE	FALSE	FALSE
## [126,]	FALSE	FALSE	FALSE	FALSE
## [127,]	FALSE	FALSE	FALSE	FALSE
## [128,]	FALSE	FALSE	FALSE	FALSE
## [129,]	FALSE	FALSE	FALSE	FALSE
## [130,]	FALSE	FALSE	FALSE	FALSE
## [131,]	FALSE	FALSE	FALSE	FALSE
## [132,]	FALSE	FALSE	FALSE	FALSE
## [133,]	FALSE	FALSE	FALSE	FALSE
## [134,]	FALSE	FALSE	FALSE	FALSE
## [135,]	FALSE	FALSE	FALSE	FALSE
## [136,]	FALSE	FALSE	FALSE	FALSE
## [137,]	FALSE	FALSE	FALSE	FALSE
## [138,]	FALSE	FALSE	FALSE	FALSE
## [139,]	FALSE	FALSE	FALSE	FALSE
## [140,]	FALSE	FALSE	FALSE	FALSE
## [141,]	FALSE	FALSE	FALSE	FALSE
## [142,]	FALSE	FALSE	FALSE	FALSE
## [143,]	FALSE	FALSE	FALSE	FALSE
## [144,]	FALSE	FALSE	FALSE	FALSE
##	Commentaire			
## [1,]	FALSE			
## [2,]	FALSE			
## [3,]	FALSE			
## [4,]	FALSE			
## [5,]	FALSE			
## [6,]	FALSE			
## [7,]	FALSE			
## [8,]	FALSE			
## [9,]	FALSE			
## [10,]	FALSE			
## [11,]	FALSE			
## [12,]	FALSE			
## [13,]	FALSE			
## [14,]	FALSE			
## [15,]	FALSE			

##	[16,]	FALSE
##	[17,]	FALSE
##	[18,]	FALSE
##	[19,]	TRUE
##	[20,]	FALSE
##	[21,]	FALSE
##	[22,]	FALSE
##	[23,]	FALSE
##	[24,]	FALSE
##	[25,]	FALSE
##	[26,]	FALSE
##	[27,]	FALSE
##	[28,]	FALSE
##	[29,]	FALSE
##	[30,]	FALSE
##	[31,]	FALSE
##	[32,]	FALSE
##	[33,]	FALSE
##	[34,]	FALSE
##	[35,]	FALSE
##	[36,]	FALSE
##	[37,]	FALSE
##	[38,]	FALSE
##	[39,]	FALSE
##	[40,]	FALSE
##	[41,]	FALSE
##	[42,]	FALSE
##	[43,]	FALSE
##	[44,]	FALSE
##	[45,]	FALSE
##	[46,]	FALSE
##	[47,]	FALSE
##	[48,]	FALSE
##	[49,]	TRUE
##	[50,]	FALSE
##	[51,]	FALSE
##	[52,]	FALSE
##	[53,]	FALSE
##	[54,]	FALSE
##	[55,]	FALSE
##	[56,]	FALSE
##	[57,]	FALSE
##	[58,]	FALSE
##	[59,]	FALSE
##	[60,]	FALSE
##	[61,]	TRUE
##	[62,]	TRUE
##	[63,]	FALSE
##	[64,]	FALSE
##	[65,]	FALSE

##	[66,]	FALSE
##	[67,]	TRUE
##	[68,]	FALSE
##	[69,]	FALSE
##	[70,]	FALSE
##	[71,]	FALSE
##	[72,]	FALSE
##	[73,]	FALSE
##	[74,]	FALSE
##	[75,]	FALSE
##	[76,]	FALSE
##	[77,]	FALSE
##	[78,]	TRUE
##	[79,]	FALSE
##	[80,]	FALSE
##	[81,]	TRUE
##	[82,]	FALSE
##	[83,]	TRUE
##	[84,]	FALSE
##	[85,]	FALSE
##	[86,]	FALSE
##	[87,]	FALSE
##	[88,]	FALSE
##	[89,]	FALSE
##	[90,]	FALSE
##	[91,]	FALSE
##	[92,]	FALSE
##	[93,]	FALSE
##	[94,]	FALSE
##	[95,]	FALSE
##	[96,]	FALSE
##	[97,]	FALSE
##	[98,]	FALSE
##	[99,]	FALSE
##	[100,]	TRUE
##	[101,]	FALSE
##	[102,]	TRUE
##	[103,]	FALSE
##	[104,]	FALSE
##	[105,]	FALSE
##	[106,]	FALSE
##	[107,]	FALSE
##	[108,]	FALSE
##	[109,]	FALSE
##	[110,]	FALSE
##	[111,]	FALSE
##	[112,]	FALSE
##	[113,]	FALSE
##	[114,]	FALSE
##	[115,]	FALSE

```
## [116,] FALSE
## [117,] FALSE
## [118,] FALSE
## [119,] FALSE
## [120,] FALSE
## [121,] FALSE
## [122,] FALSE
## [123,] FALSE
## [124,] FALSE
## [125,] FALSE
## [126,] FALSE
## [127,] TRUE
## [128,] FALSE
## [129,] FALSE
## [130,] TRUE
## [131,] FALSE
## [132,] FALSE
## [133,] FALSE
## [134,] FALSE
## [135,] FALSE
## [136,] FALSE
## [137,] FALSE
## [138,] TRUE
## [139,] FALSE
## [140,] FALSE
## [141,] FALSE
## [142,] FALSE
## [143,] FALSE
## [144,] FALSE
```

```
na_col = colSums(is.na(df))
na_col
```

```
##          Obs_ID          Station          Localite
##          0          0          0
##      Type_zone      Usage_sol  Risque_inondation
##          0          0          0
##          Date      Temperature_C      Humidite_pct
##          0          17          17
##      Pluie_mm      Vent_mps      PM25_ugm3
##          17          17          17
##      NO2_ppb      Bruit_dB      NDVI
##          17          17          17
##      Perception_air_1a5      Gene_bruit_1a5      Qualite_capteur
##          17          17          17
##      Brulage_dechets      Phase_intervention      Campagne
##          17          120          0
##      Agent_collecteur      Numero_serie_capteur      Commentaire
##          0          0          13
```

```
Taux_NA = colMeans(is.na(df)) * 100
```

```
Taux_NA
```

```
##          Obs_ID          Station          Localite
##          0.000000          0.000000          0.000000
##          Type_zone          Usage_sol  Risque_inondation
##          0.000000          0.000000          0.000000
##          Date          Temperature_C          Humidite_pct
##          0.000000          11.805556          11.805556
##          Pluie_mm          Vent_mps          PM25_ugm3
##          11.805556          11.805556          11.805556
##          NO2_ppb          Bruit_dB          NDVI
##          11.805556          11.805556          11.805556
##          Perception_air_1a5          Gene_bruit_1a5          Qualite_capteur
##          11.805556          11.805556          11.805556
##          Brulage_dechets          Phase_intervention          Campagne
##          11.805556          83.333333          0.000000
##          Agent_collecteur          Numero_serie_capteur          Commentaire
##          0.000000          0.000000          9.027778
```

```
Taux_NA_filtre = Taux_NA[Taux_NA > 0]
```

```
Taux_NA_filtre
```

```
##          Temperature_C          Humidite_pct          Pluie_mm          Vent_mp
s
##          11.805556          11.805556          11.805556          11.80555
6
##          PM25_ugm3          NO2_ppb          Bruit_dB          NDV
I
##          11.805556          11.805556          11.805556          11.80555
6
##          Perception_air_1a5          Gene_bruit_1a5          Qualite_capteur          Brulage_dechet
s
##          11.805556          11.805556          11.805556          11.80555
6
##          Phase_intervention          Commentaire
##          83.333333          9.027778
```


```
barplot(Taux_NA_filtre,
```

```
  las = 2,
```

```
  col = "steelblue",
```

```
  ylab = "Pourcentage de valeurs manquantes (%)",
```

```
  main = "Variables contenant des valeurs manquantes")
```



#Commentaire: ce

graphique montre la proportion des données manquantes par variables contenant des valeurs manquantes. Presque toutes les variables ont un taux de NA de 17% , sauf la variable “Phase_intervention” qui a en 80% et la variable Commentaire de 13%

#2.Traitements des NA

```
pluie = df$Pluie_mm[is.na(df$Pluie_mm)]=median(df$Pluie_mm,na.rm =TRUE)
no2 = df$NO2_ppb[is.na(df$NO2_ppb)]=median(df$NO2_ppb,na.rm =TRUE)
temp = df$Temperature_C[is.na(df$Temperature_C)]=median(df$Temperature_C,na.rm =TRUE)
vent = df$Vent_mps[is.na(df$Vent_mps)]=median(df$Vent_mps,na.rm =TRUE)
bruit = df$Bruit_dB[is.na(df$Bruit_dB)]=median(df$Bruit_dB,na.rm =TRUE)
humidite = df$Humidite_pct[is.na(df$Humidite_pct)]=median(df$Humidite_pct,na.rm =TRUE)
pm25 = df$PM25_ugm3[is.na(df$PM25_ugm3)]=median(df$PM25_ugm3,na.rm =TRUE)
ndvi = df$NDVI[is.na(df$NDVI)]=median(df$NDVI,na.rm =TRUE)
percep_air_1a5 =df$Perception_air_1a5[is.na(df$Perception_air_1a5)] = median(df$Perception_air_1a5,na.rm =TRUE)
gene_bruit_1a5=df$Gene_bruit_1a5[is.na(df$Gene_bruit_1a5)] = median(df$Gene_bruit_1a5,na.rm =TRUE)
```

,

```
mode_qual <- function(x) {
  ux <- na.omit(x)
  ux[which.max(tabulate(match(ux, ux)))]
}
vars_quali <- names(df)[sapply(df, is.factor)]
```



```
vars_quali <- names(df)[sapply(df, function(x) is.factor(x) | is.character(x)
)]

for (v in vars_quali) {
  mode_v <- mode_qual(df[[v]])
  df[[v]][is.na(df[[v]])] <- mode_v
}

View(df)
```

#Justification : J'ai utilisé l'imputation par médiane/mode pour préserver les caractéristiques locales(pour ne pas fausser l'analyse).j'ai remplacé les NA par le mode pour les variables qualitatives car leur taux de NA est supérieur à 5% et les variables quantitatives par la médiane vu que le taux de NA est supérieur à 5%

```
View(df)
```

#Resume de la BD

```
summary(df)
```

```
##      Obs_ID      Station      Localite      Type_zone
## Min.   : 1.00   Length:144   Length:144   Length:144
## 1st Qu.: 36.75   Class :character Class :character Class :character
## Median : 72.50   Mode  :character Mode  :character Mode  :character
## Mean    : 72.50
## 3rd Qu.:108.25
## Max.    :144.00
##      Usage_sol      Risque_inondation      Date
## Length:144   Length:144   Min.    :2025-01-01 00:00:00
## Class :character Class :character 1st Qu.:2025-03-24 06:00:00
## Mode  :character Mode  :character Median :2025-06-16 00:00:00
##                                     Mean    :2025-05-31 14:00:00
##                                     3rd Qu.:2025-08-08 18:00:00
##                                     Max.    :2025-10-01 00:00:00
##      Temperature_C      Humidite_pct      Pluie_mm      Vent_mps
## Min.    :23.72   Min.    :31.66   Min.    : 0.04086   Min.    :0.200
## 1st Qu.:27.66   1st Qu.:59.20   1st Qu.: 4.11492   1st Qu.:2.342
## Median :29.08   Median :71.26   Median :10.11856   Median :2.900
## Mean    :29.25   Mean    :69.04   Mean    :17.32907   Mean    :2.959
## 3rd Qu.:30.42   3rd Qu.:78.49   3rd Qu.:20.92118   3rd Qu.:3.569
## Max.    :34.90   Max.    :95.00   Max.    :320.00000   Max.    :6.340
##      PM25_ugm3      NO2_ppb      Bruit_dB      NDVI
## Min.    : 4.00   Min.    : 2.00   Min.    : 40.29   Min.    : -0.2500
## 1st Qu.:23.78   1st Qu.:15.60   1st Qu.:55.61   1st Qu.: 0.2360
## Median :34.60   Median :22.39   Median :61.88   Median : 0.3050
## Mean    :42.34   Mean    :23.36   Mean    :60.96   Mean    : 0.3549
## 3rd Qu.:48.56   3rd Qu.:29.60   3rd Qu.:66.03   3rd Qu.: 0.4667
## Max.    :520.00   Max.    :180.00   Max.    :110.00   Max.    : 1.2500
##      Perception_air_1a5      Gene_bruit_1a5      Qualite_capteur      Brulage_dechets
```


```
## Min. :2.000 Min. :1.000 Length:144 Length:144
## 1st Qu.:4.000 1st Qu.:2.000 Class :character Class :character
## Median :4.000 Median :2.000 Mode :character Mode :character
## Mean :4.083 Mean :2.194
## 3rd Qu.:4.000 3rd Qu.:3.000
## Max. :5.000 Max. :4.000
## Phase_intervention Campagne Agent_collecteur Numero_serie_cap
teur
## Length:144 Length:144 Length:144 Length:144
## Class :character Class :character Class :character Class :character
## Mode :character Mode :character Mode :character Mode :character
##
##
##
## Commentaire
## Length:144
## Class :character
## Mode :character
##
##
##

df$Station = as.factor(df$Station)
df$Localite = as.factor(df$Localite)
df$Type_zone = as.factor(df$Type_zone)
df$Usage_sol = as.factor(df$Usage_sol)
df$Risque_inondation = as.factor(df$Risque_inondation)
df$Qualite_capteur = as.factor(df$Qualite_capteur)
df$Brulage_dechets = as.factor(df$Brulage_dechets )
df$Phase_intervention = as.factor(df$Phase_intervention )
df$Campagne = as.factor(df$Campagne)
df$Agent_collecteur = as.factor(df$Agent_collecteur)
df$Numero_serie_capteur = as.factor(df$Numero_serie_capteur)
df$Commentaire = as.factor(df$Commentaire)
```

#3.detection des valeurs aberrantes


```
boxplot(df$PM25_ugm3, main = "Detection des valeurs aberrantes(PM25_ugm3)")
```

Detection des valeurs aberrantes(PM25_ugm3)




```
boxplot(df$NO2_ppb, main = "Detection des valeurs aberrantes(NO2_ppb)")
```

Detection des valeurs aberrantes(NO2_ppb)




```
boxplot(df$Bruit_dB, main = "Detection des valeurs aberrantes(Bruit_dB)")
```

Detection des valeurs aberrantes(Bruit_dB)



```
boxplot(df$NDVI, main = "Detection des valeurs aberrantes(NDVI)")
```

Detection des valeurs aberrantes(NDVI)



#Strategie:Je vais winsoriser les valeurs extrêmes (remplacer par les bornes IQR) car :

Certaines valeurs pourraient être réelles

La suppression réduirait trop l'échantillon

Le winsorizing préserve la structure des données

```
# Winsorisation des outliers
df$PM25_ugm3[df$PM25_ugm3<4] = 4
df$PM25_ugm3[df$PM25_ugm3>90.25] = 90.25
df$NO2_ppb[df$NO2_ppb<2.25] = 2.25
df$NO2_ppb[df$NO2_ppb>49] = 49
df$Bruit_dB[df$Bruit_dB<40.25] = 40.25
df$Bruit_dB[df$Bruit_dB>79] = 79
df$NDVI[df$NDVI<0.25] = 0.25
df$NDVI[df$NDVI>0.8] = 0.8
```

View(df)

#B.Suppression de colonnes(obligatoire)

```
df$Agent_collecteur = NULL
df$Numero_serie_capteur = NULL
df$Commentaire = NULL
```

#C.Ajout de nouvelles colonnes (obligatoire) #1.Saison

```
data_NA = df
df$Saison = ifelse(
  as.numeric(format(df$Date, "%m")) %in% c(6, 7, 8, 9, 10),
  "Pluie",
  "Seche"
)
print(df$Saison)

## [1] "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Sec
he"
## [10] "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Sec
he"
## [19] "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Sec
he"
## [28] "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Sec
he"
## [37] "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Sec
he"
## [46] "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Sec
he"
## [55] "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Seche" "Pluie" "Pluie" "Plu
ie"
## [64] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
```

```

ie"
## [73] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"
## [82] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"
## [91] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"
## [100] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"
## [109] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"
## [118] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"
## [127] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"
## [136] "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Pluie" "Plu
ie"

```

#2.Depassement_PM25

```

df$Depassement_PM25 = ifelse(
  df$PM25_ugm3 > 55,
  "Oui",
  "Non"
)

```

#3.PM25_log

```

df$PM25_log = log(df$PM25_ugm3)

```

#4.Indice_confort (simple)

```

df$Indice_confort = df$Temperature_C +
  0.1 * df$Humidite_pct

```

```

View(df)


```

#D.Visualisations #Histogramme de PM25_ugm3

```

ggplot(df, aes(x = PM25_ugm3)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  theme_minimal() +
  labs(title = "Histogrammes de PM25_ugm3",
       x = "PM25(µg/m³)",
       y = "Fréquence")


```



#Commentaire:L'histogramme montre que la majorité des concentrations de PM2.5 est faible , avec une forte concentration des observations environ entre 20 et 60 $\mu\text{g}/\text{m}^3$.

#Histogramme de NO2_ppb


```
ggplot(df, aes(x = NO2_ppb)) +  
  geom_histogram(bins = 30, fill = "darkorange", color = "white") +  
  theme_minimal() +  
  labs(title = "Histogramme de NO2",  
        x = "NO2 (ppb)",  
        y = "Fréquence")
```



#Commentaire:L'histogramme montre que la majorité des concentrations de NO2 (dioxyde d'azote)est faible entre 0 et 50ppb et une fréquence plus élevée (40) .La distribution est probablement asymétrique à droite et aucune barre significative au delà de 100ppb.


#Histogramme de Bruit_dB

```
ggplot(df, aes(x = Bruit_dB)) +  
  geom_histogram(bins = 30, fill = "gray50", color = "white") +  
  theme_minimal() +  
  labs(title = "Histogramme du bruit",  
        x = "Bruit ",  
        y = "Fréquence")
```


#Commentaire:la distribution n'est pas symétrique. #on constate une diminution des fréquences de part et d'autre du pic de fréquence 30 #Boxplots de PM25_ugm3

```
ggplot(df, aes(y = PM25_ugm3)) +  
  geom_boxplot(fill = "steelblue") +  
  theme_minimal() +  
  labs(title = "Boxplot de PM2.5",  
        y = "PM2.5 (µg/m³)")
```




#Boxplots de NO2_ppb

```
ggplot(df, aes(y = NO2_ppb)) +  
  geom_boxplot(fill = "darkorange") +  
  theme_minimal() +  
  labs(title = "Boxplot de NO2",  
        y = "NO2(ppb)")
```




#Boxplots de Bruit_dB

```
ggplot(df, aes(y = Bruit_dB)) +  
  geom_boxplot(fill = "gray60") +  
  theme_minimal() +  
  labs(title = "Boxplot du bruit",  
        y = "Bruit (dB)")
```




#Boxplots de PM25_ugm3 par Type_zone

```
ggplot(df, aes(x = Type_zone, y = PM25_ugm3, fill = Type_zone)) +  
  geom_boxplot() +  
  theme_minimal() +  
  labs(title = "PM2.5 selon le type de zone",  
        x = "Type de zone",  
        y = "PM2.5 ( $\mu\text{g}/\text{m}^3$ )")
```



#Commentaire: on constate que la pollution est plus fréquente dans le milieu urbain que dans le milieu périurbain et très faible dans le milieu rural. #Boxplots de PM25_ugm3 par Usage_sol


```
ggplot(df, aes(x = Usage_sol, y = PM25_ugm3, fill = Usage_sol)) +
  geom_boxplot() +
  theme_minimal() +
  labs(title = "PM2.5 selon l'usage du sol",
       x = "Usage du sol",
       y = "PM2.5 (µg/m³)")
```



#Commentaire:

```
#Scatter PM25_ugm3 vs N02_ppb(avec tendance)
ggplot(df, aes(x = N02_ppb, y = PM25_ugm3)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  theme_minimal() +
  labs(title = "Relation entre PM2.5 et N02",
       x = "N02 (ppb)",
       y = "PM2.5 (µg/m³)")

## `geom_smooth()` using formula = 'y ~ x'
```




#Commentaire:le graphique montre la relation entre le PM2.5 et NO2 .le nuage de point montre que lorsque le dioxyde d'azote (NO2) augmente les matières particulaires dans l'air(PM2.5) augmente généralement.

#Scatter PM25_ugm3 vs NDVI

```
ggplot(df, aes(x = NDVI, y = PM25_ugm3)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "loess", se = FALSE) +
  theme_minimal() +
  labs(title = "Relation entre PM2.5 et la végétation (NDVI)",
        x = "NDVI",
        y = "PM2.5 ( $\mu\text{g}/\text{m}^3$ )")

## `geom_smooth()` using formula = 'y ~ x'
```




#Commentaire: Le nuage de point montre que lorsque la végétation augmente la pollution diminue .

#serie temporelle

```
df$Mois = format(df$Date, "%m")

pm25_mensuel= df %>%
  group_by(Mois) %>%
  summarise(PM25_moy = mean(PM25_ugm3, na.rm = TRUE))

ggplot(pm25_mensuel, aes(x = Mois, y = PM25_moy, group = 1)) +
  geom_line() +
  geom_point() +
  theme_minimal() +
  labs(title = "Évolution mensuelle moyenne du PM2.5",
       x = "Mois",
       y = "PM2.5 moyen (µg/m³)") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```


#Commentaire:le

graphe illustre clairement que le PM2.5 moyen atteint un pic entre mars et mai avec une concentration maximale probablement atteinte en avril.

#Heatmap/Corrélogramme(pour les variables quantitatives)

```
#Heatmap/corrélogramme (sur quanti)
#garder uniquement les variable quantitatives
df_quant <- df[, sapply(df, is.numeric)]
#calculer la matrice de corrélation
cor_mat <- cor(df_quant, use = "complete.obs")
#préparer pour les données ggplot
cor_long <- melt(cor_mat)
library(ggplot2)
ggplot(cor_long, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile(color = "white") +
  scale_fill_gradient2(
    low = "blue",
    mid = "white",
    high = "red",
    midpoint = 0,
    name = "Corrélation"
  ) +
  geom_text(aes(label = round(value, 2)), size = 2) +
  labs(title = "Heatmap des variables quantitatives",
       x = "", y = "") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

Heatmap des variables quantitatives



#Commentaire : ce graphique montre la corrélation entre deux variables quantitatives et la corrélation d'une variable par lui-même. Soit ces deux variables sont fortement corrélées, négativement si la valeur est proche de -1, soit elles sont fortement corrélées positivement si la valeur est proche de 1. Si la valeur est proche de 0 pas de corrélation linéaire significative. On peut dire que le NDVI et le gène bruit 1a5 sont fortement corrélés négativement car c'est proche de -1. On peut dire aussi que Obs_ID et Humidite_pct sont fortement corrélés car c'est proche de 1. Également l'indice_confort et Temperature_c sont fortement corrélés positivement car la valeur est proche de 1.

#PARTIE 3:

#Question 1: Le dépassement PM25 dépend-t-il du type de zone?

#Analyse univariee

```
tab = table(df$Depassement_PM25)
tab
```

```
##
```

```
## Non Oui
```

```
## 121 23
```

```
tab = table(df$Type_zone)
tab
```


```
##
## Périurbain      Rural      Urbain
##           48           36           60

#Analyse bivariée
#Tableau de contingence
tab1 = table(df$Depassement_PM25,df$Type_zone)
tab1

##
##      Périurbain Rural Urbain
## Non           45    35    41
## Oui            3     1    19

#Commentaire:il y'a 45 zones périurbaines,35 zones rurales,41 zones urbaines,
dont leur PM25 est inférieur à 55µg/m³ et 3 zones périurbaines ,1 zone rurale
et 19 zones urbaines dont leur PM25 est supérieur à 55µg/m³.

#Répartition du dépassement PM25 selon le type de zone
ggplot(df, aes(x =Type_zone, fill = Depassement_PM25)) +
  geom_bar(position = "fill") +
  labs(title = "Répartition du dépassement PM25 selon le type de zone",
       x = "Type_zone", y = "Proportion") +
  theme_minimal()
```



#Commentaire:Le graphe montre que 30% des zones urbaines,5%des zones rurales, 10% des zones périurbaines ont un depassement PM2.5 >55µg/m³.

Donc on peut dire que la pollution est plus fréquente dans les zones urbaines .

#Test du Chi-deux d'indépendance

chi <- chisq.test(tab1) #on utilise le test de chi-deux parce que les variables sont catégorielles et les effectifs sont supérieurs à 5

chi #et chaque individu appartient à une seule catégorie pour chaque variable

##

Pearson's Chi-squared test

##

data: tab1

X-squared = 19.062, df = 2, p-value = 7.257e-05

#Mesure d'intensité : V de Cramer

library(vcd)

assocstats(tab1)

X^2 df P(> X^2)

Likelihood Ratio 19.989 2 4.5641e-05

Pearson 19.062 2 7.2566e-05

##

Phi-Coefficient : NA

Contingency Coeff.: 0.342

Cramer's V : 0.364

#Le test de chi-deux montre que la p-value est inférieure à 0.05 ,donc

#Le dépassement PM25 dépend du type de zone et l'association est forte

#Commentaire:le graphe montre que 30% des zones urbaines,5%des zones rurales,10% des zones périurbaines ont un dépassement PM2.5 >55µg/m³. Donc on peut dire que la pollution est plus fréquente dans les zones urbaines.

#Question2:Le brûlage de déchets dépend-t-il de la zone (urbain/périurbain/rural) ?

#Analyse univariée

#Tableau de contingence

tab <- table(df\$Brulage_dechets, df\$Type_zone)

#visualisation des variables


ggplot(df, aes(x = Type_zone, fill = Brulage_dechets)) +

geom_bar(position = "fill") +

labs(title = "Répartition du type de zone selon le brûlage de déchets",

x = "Type_zone", y = "Proportion") +

theme_minimal()



*#Test d'indépendance du Chi-deux (Les effectifs sont supérieur à 5)
 ##H0 IL y'a pas de liaison entre les 2 variables qualitatives
 ##H1 IL y'a une liaison entre les 2 variables qualitatives
 #Le test de chi-deux montre que la p-value est inférieure à 0.05*

```
chi <- chisq.test(tab)
chi

##
## Pearson's Chi-squared test
##
## data:  tab
## X-squared = 1.2308, df = 2, p-value = 0.5404
```

#La p-value est supérieure à 0.05 donc il y'a pas de liaison entre le brûlage de déchets et le type de zone cela infirme les résultats obtenus à la visualisation

#Commentaire: on constate que le brûlage des déchets est plus fréquent en zone rurale qu'en zone urbaine et périurbaine et est légèrement plus élevé en zone urbaine qu'en zone périurbaine. #donc d'après cette visualisation, on peut dire que le brûlage de déchets dépend du type de zone.

#Question 3 : Quanti × Quanti #PM2.5 est-il corrélé au NO2 ?


```
# Description univariée
```

```
# Pour le PM2.5
```

```
summary(df$PM25_ugm3)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      4.00  23.78   34.60   36.85  48.56   90.25
```

```
boxplot(df$PM25_ugm3)
```




```
#Pour le NO2
```

```
summary(df$NO2_ppb)
```


```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      2.25  15.60   22.39   22.43  29.60   49.00
```

```
boxplot(df$NO2_ppb)
```



```
# Description bivariée
#Nuage de points entre les 2 variables
plot(df$PM25_ugm3, df$N02_ppb,
      main = "Relation entre PM25 et N02",
      xlab = "PM25(µg/m³)", ylab = "N02")
```

Relation entre PM25 et NO2



```
#Vérification de la linéarité et de la normalité
#Pour la linéarité
plot(df$PM25_ugm3, df$NO2_ppb,
     main = "Relation entre PM25 et NO2",
     xlab = "PM25(µg/m³)", ylab = "NO2")
#la linéarité entre les 2 variables n'est pas vérifiée(non linéaire)
#Pour la normalité
shapiro.test(df$PM25_ugm3)

##
##  Shapiro-Wilk normality test
##
## data:  df$PM25_ugm3
## W = 0.97352, p-value = 0.006827

shapiro.test(df$NO2_ppb)

##
##  Shapiro-Wilk normality test
##
## data:  df$NO2_ppb
## W = 0.98333, p-value = 0.07793

#la normalité est rejetée car la p-value est inférieur à 0.05
# Test de corrélation
cor.test(df$PM25_ugm3, df$NO2_ppb, method="spearman")
```



```
## Warning in cor.test.default(df$PM25_ugm3, df$N02_ppb, method = "spearman")
:
## Impossible de calculer la p-value exacte avec des ex-aequos

##
## Spearman's rank correlation rho
##
## data: df$PM25_ugm3 and df$N02_ppb
## S = 213286, p-value = 7.48e-14
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##      rho
## 0.5714043
```

*#On utilise spearman car la linéarité et la normalité ne sont pas vérifiées
#D'après le coefficient de corrélation de spearman il y'a une forte corrélation positive entre le PM2.5 et le N02*

#On constate que lorsque le PM2.5 augmente le N02 augmente aussi .

#Question 4:Quanti × Quanti #La végétation (NDVI) est-elle associée à la pollution (PM2.5) ?


Description univariée

Pour la végétation

```
summary(df$NDVI)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.2500 0.2500 0.3050 0.3815 0.4667 0.8000
```

```
boxplot(df$NDVI)
```




#Pour la pollution

```
summary(df$PM25_ugm3)
```


##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	4.00	23.78	34.60	36.85	48.56	90.25

```
boxplot(df$PM25_ugm3)
```



```
# Description bivariee
#Nuage de points entre les 2 variables
plot(df$NDVI, df$PM25_ugm3,
      main = "Relation entre la v g tation (NDVI) et la pollution(PM2.5)",
      xlab = "NDVI", ylab = "PM25( g/m 3)")
```

Relation entre la végétation (NDVI) et la pollution(PM



```
#Vérification de la linéarité et de la normalité
#Pour la linéarité
plot(df$NDVI, df$PM25_ugm3,
     main = "Relation entre la végétation (NDVI) et la pollution(PM2.5)",
     xlab = "NDVI", ylab = "PM25(µg/m³)")
#la linéarité entre les 2 variables n'est pas vérifié(NON linéaire)
#Pour la normalité
shapiro.test(df$NDVI)

##
##  Shapiro-Wilk normality test
##
## data:  df$NDVI
## W = 0.78935, p-value = 4.093e-13

shapiro.test(df$PM25_ugm3)

##
##  Shapiro-Wilk normality test
##
## data:  df$PM25_ugm3
## W = 0.97352, p-value = 0.006827

#la normalité est rejetée car la p-value est inférieur à 0.05
# Test de corrélation
cor.test(df$NDVI, df$PM25_ugm3, method="pearson")
```

```
##
## Pearson's product-moment correlation
##
## data: df$NDVI and df$PM25_ugm3
## t = -7.3657, df = 142, p-value = 1.315e-11
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.6347645 -0.3962886
## sample estimates:
## cor
## -0.5257816
```

*#On utilise spearman car la linéarité et la normalité ne sont pas vérifiées
#Interprétation: d'après le coefficient de corrélation de spearman il y'a une forte corrélation négative monotone entre la végétation (NDVI) et la pollution (PM2.5)*

#Commentaire: on constate que lorsque le NDVI augmente le PM2.5 diminue.

#Question 5: Quanti × Quali (2 groupes): Student / Welch / Mann-Whitney #Le PM2.5 est-il différent quand il y a brûlage (Oui/Non) ?

#--Cas avec deux modalités: Les groupes sont de deux populations indépendantes

Description univariées des variables

Pour la variable qualitative 'Brulage_dechets'

```
Brulage_dechets_table <- table(df$Brulage_dechets)
```

```
Brulage_dechets_table
```


```
##
```

```
## Non Oui
```

```
## 117 27
```

Répartition par brûlage (Oui/Non)

```
barplot(Brulage_dechets_table,
        main = "Distribution de brûlage (Oui/Non)",
        xlab = "brûlage (Oui/Non)",
        ylab = "Fréquence")
```




```
# Distribution de la variable quantitative 'PM25_ugm3'
```

```
summary(df$PM25_ugm3)
```


```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      4.00  23.78   34.60   36.85  48.56   90.25
```

```
# Histogramme de la PM2.5
```

```
ggplot(df, aes(x = PM25_ugm3)) +
  geom_histogram(binwidth = 0.5, fill = "blue", color = "black") +
  labs(title = "PM2.5 selon la présence ou non de brûlage de déchets",
       x = "PM2.5(µg/m³)",
       y = "Fréquence") +
  theme_minimal()
```



```
# Description bivariée et formulation d'une hypothèse
# Boxplot de PM2.5 par brûlage (Oui/Non)
ggplot(df, aes(x = Brulage_dechets, y = PM25_ugm3, fill = Brulage_dechets)) +
  geom_boxplot() +
  labs(title = "PM2.5 selon la présence de brûlage de déchets ",
        x = " Brûlage",
        y = "PM2.5(µg/m³)") +
  theme_minimal()
```



```
# Tests Statistiques
# Test paramétrique (Test de Student et Test de Welch)
# vérification des hypotheses

# 1) Normalité globale (ou par groupe si on veut être plus strict)
# Test de Shapiro-Wilk pour la variable quantitative 'PM25_ugm3'
# H0 : normalité
# H1 : pas de normalité
library(car)

## Le chargement a nécessité le package : carData

##
## Attachement du package : 'car'

## L'objet suivant est masqué depuis 'package:dplyr':
##
##      recode

shapiro_test_total = shapiro.test(df$PM25_ugm3)
print(shapiro_test_total)

##
##  Shapiro-Wilk normality test
##
## data:  df$PM25_ugm3
## W = 0.97352, p-value = 0.006827
```



```

#La p-value = 2.2e-16 et est inférieur à 0.05 donc la normalité est rejetée
# 2) égalité des variances : Test de Levene(car Les échantillons sont indépendantes)
library(car)
levene_test = leveneTest(PM25_ugm3 ~ Brulage_dechets, data = df)
print(levene_test)

## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group 1  3.9714 0.0482 *
##      142
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

#H0: Les variances des différents groupes sont égales.
#H1: Au moins une des variances des différents groupes est différente.
#Les variances des différents groupes sont égales car la p-value = 0.1083 et est supérieur à 0.05
#Test de Mann-Whitney(car Les échantillons sont indépendantes et la normalité est rejetée)
#H0: Les distributions des deux groupes sont égales.
#H1: Les distributions des deux groupes sont différentes
test_q5 = wilcox.test(PM25_ugm3 ~ Brulage_dechets,
                      data = df,
                      exact = FALSE)

test_q5

##
## Wilcoxon rank sum test with continuity correction
##
## data:  PM25_ugm3 by Brulage_dechets
## W = 1435, p-value = 0.4606
## alternative hypothesis: true location shift is not equal to 0

#La p-value est supérieure à 0.05 donc on rejette H1
#il y en pas de distribution significative entre le PM2.5 et le brulage (Oui/Non).

```

#Interprétation: On peut dire que le brulage de déchets a un impact significatif sur l'augmentation des particules fines PM2.5.

#Question 6: Quanti × Quali (2 groupes) : bruit et industrie #Le bruit est-il plus élevé en zone industrielle (oui/non) ?

```

df$industriel_oui_non=ifelse(df$Usage_sol=="Industriel",
                             "oui", "non")

#--Cas avec deux modalités: Les groupes sont de deux populations indépendantes
# Description univariées des variables

```


```

# Pour la variable qualitative 'industriel_oui_non'
industriel_oui_non_table <- table(df$industriel_oui_non)
industriel_oui_non_table

##
## non oui
## 120  24

# Répartition de zone industrielle (Oui/Non)
barplot(industriel_oui_non_table,
        main = "Distribution de zone industrielle (Oui/Non)",
        xlab = "zone industrielle (Oui/Non)",
        ylab = "Fréquence")

```




```

# Distribution de la variable quantitative 'Bruit_dB'
summary(df$Bruit_dB)


##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  40.29   55.61   61.88   60.75   66.03   79.00

# Histogramme de la Bruit_dB
ggplot(df, aes(x = Bruit_dB)) +
  geom_histogram(binwidth = 0.5, fill = "blue", color = "black") +
  labs(title = "Bruit selon la présence ou non de zone industrielle",
        x = "Bruit_dB",
        y = "Fréquence") +
  theme_minimal()

```



```
# Description bivariée et formulation d'une hypothèse
# Boxplot de Bruit_dB par brûlage (Oui/Non)
ggplot(df, aes(x = industriel_oui_non , y = Bruit_dB, fill = industriel_oui_n
on )) +
  geom_boxplot() +
  labs(title = "Bruit_dB selon la présence d'industrie ",
       x = " industriel_oui_non",
       y = "Bruit_dB") +
  theme_minimal()
```



```
# Tests Statistiques
# Test paramétrique
# vérification des hypotheses

# 1) Normalité globale (ou par groupe si on veut être plus strict)
# Test de Shapiro-Wilk pour la variable quantitative 'Bruit_dB'
# H0 : normalité
# H1 : pas de normalité
library(car)
shapiro_test_total = shapiro.test(df$Bruit_dB)
print(shapiro_test_total)

##
##  Shapiro-Wilk normality test
##
## data:  df$Bruit_dB
## W = 0.96569, p-value = 0.001134

#La p-value est inférieur à 0.05 donc la normalité est rejetée
# 2) égalité des variances : Test de Levene(car les échantillons sont indépen
dantes)
library(car)
levene_test = leveneTest(Bruit_dB ~ industriel_oui_non, data = df)

## Warning in leveneTest.default(y = y, group = group, ...): group coerced to
## factor.
```

```

print(levene_test)

## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group  1  1.0225 0.3136
##      142

#Les variances des différents groupes sont égales car la p-value est supérieur à 0.05
#Test de Mann-Whitney(car les échantillons sont indépendantes et la normalité est rejetée)
#H0: Les distributions des deux groupes sont égales.
#H1: Les distributions des deux groupes sont différentes
test_q5 = wilcox.test(Bruit_dB ~ industriel_oui_non,
                      data = df,
                      exact = FALSE)

test_q5

##
## Wilcoxon rank sum test with continuity correction
##
## data:  Bruit_dB by industriel_oui_non
## W = 556.5, p-value = 2.158e-06
## alternative hypothesis: true location shift is not equal to 0

#la p-value est inférieur à 0.05 donc on rejette H0
#bruit et la zone industrielle ont des distributions différentes .

```

#Commentaire: on constate que lorsqu'il y'a la présence d'industrie le bruit augmente.

#Question 7: Quanti × Quali (>2 groupes) : ANOVA / Welch ANOVA / Kruskal-Wallis #Le bruit diffère-t-il selon le type de zone ?


```

#1. Description univariée
# Type de zone
table_type_zone <- table(df$Type_zone)
print(table_type_zone)

##
## Périurbain      Rural      Urbain
##          48          36          60

barplot(table_type_zone,
        main = "Répartition des types de zone",
        xlab = "Types de zone",
        ylab = "Fréquence")


```




```
#Bruit
summary(df$Bruit_dB)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  40.29   55.61   61.88   60.75   66.03   79.00

hist(df$Bruit_dB,
     main = "Distribution du bruit",
     xlab = "Bruit",
     col = "skyblue",
     border = "black")
```



```
#2.Description bivariable  
#Boxplot bruit x type de zone  
ggplot(df, aes(x = Type_zone, y = Bruit_dB, fill = Type_zone)) +  
  geom_boxplot() +  
  labs(title = "Bruit selon le type de zone",  
        x = "type de zone",  
        y = "Bruit") +  
  theme_minimal()
```



#3. Tests statistiques

vérification de la normalité

```
shapiro.test(df$Bruit_dB)
```

```
##
```

```
## Shapiro-Wilk normality test
```

```
##
```

```
## data: df$Bruit_dB
```

```
## W = 0.96569, p-value = 0.001134
```

#La normalité est rejetée car la p-value est inférieure à 0.05

vérification de l'égalité des variances (Levene)

```
library(car)
```

```
leveneTest(Bruit_dB ~ Type_zone, data = df)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
```

```
##      Df F value Pr(>F)
```

```
## group 2  3.6118 0.02953 *
```

```
##      141
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

la p-value est inférieure à 0.05 donc au moins une des variances des différents groupes est différente

Test de Kruskal-Wallis (ce n'est pas paramétrique)

#H0: Les k populations ont la même distribution ou Les médianes des groupes s

ont égales.

#H1: au moins un groupe a une distribution différente.

```
kruskal_test <- kruskal.test(Bruit_dB ~ Type_zone, data = df)
print(kruskal_test)
```

```
##
```

```
## Kruskal-Wallis rank sum test
```

```
##
```

```
## data: Bruit_dB by Type_zone
```

```
## Kruskal-Wallis chi-squared = 79.329, df = 2, p-value < 2.2e-16
```

#La p-value est inférieur à 0.05 alors on rejette H0

#Le bruit diffère selon le type de zone (au moins en 1 groupe)

#Interprétation: on constate que le bruit est plus élevé en zone urbaine ,qu'au zone périurbaine et rurale

#Question 8: Quanti × Quali (>2 groupes) #Le PM2.5 diffère-t-il selon l'usage du sol ?

#1. Description univariée

Usage du sol


```
table_usage_sol <- table(df$Usage_sol)
print(table_usage_sol)
```

```
##
```

```
##      Agricole  Industriel      Mixte Résidentiel
```

```
##           60           24           24           36
```

```
barplot(table_usage_sol,
        main = "Répartition des types d'usage du sol",
        xlab = "Usage du sol",
        ylab = "Fréquence")
```




```
#PM2.5
summary(df$PM25_ugm3)


##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
##    4.00   23.78   34.60   36.85   48.56   90.25 

hist(df$PM25_ugm3,
      main = "Distribution du PM2.5",
      xlab = "PM2.5( $\mu\text{g}/\text{m}^3$ )",
      col = "skyblue",
      border = "black")
```

Distribution du PM2.5



```
#2.Description bivariée
#Boxplot PM2.5 x Usage du sol
ggplot(df, aes(x = Usage_sol, y = PM25_ugm3, fill = Usage_sol)) +
  geom_boxplot() +
  labs(title = "PM2.5 selon le type d'usage du sol",
       x = "Usage du sol",
       y = "PM2.5") +
  theme_minimal()
```



#3. Tests statistiques

vérification de la normalité

```
shapiro.test(df$PM25_ugm3)
```

```
##
```

```
## Shapiro-Wilk normality test
```

```
##
```

```
## data: df$PM25_ugm3
```

```
## W = 0.97352, p-value = 0.006827
```

#La p-value est inférieure à 0.05 donc la normalité est rejetée

vérification de l'égalité des variances (Levene)

```
library(car)
```

```
leveneTest(PM25_ugm3 ~ Usage_sol, data = df)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
```

```
##      Df F value Pr(>F)
```

```
## group 3  2.9984 0.03282 *
```

```
##      140
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

#la p-value est supérieure à 0.05 donc les variances des différents groupes sont égales

Cas 2 : Hypothèses NON paramétrique ou NON respectées:

Test de Kruskal-Wallis

#H0: Les k populations ont la même distribution ou les médianes des groupes s ont égales.

#H1: au moins un groupe a une distribution différente.

```
kruskal_test <- kruskal.test(PM25_ugm3 ~ Usage_sol, data = df)
print(kruskal_test)
```

```
##
```

```
## Kruskal-Wallis rank sum test
```

```
##
```

```
## data: PM25_ugm3 by Usage_sol
```

```
## Kruskal-Wallis chi-squared = 23.792, df = 3, p-value = 2.76e-05
```

#La p-value est inférieure à 0.05 alors on rejette H0

#Le PM2.5 diffère selon l'usage du sol (au moins 1 groupe)

#Commentaire:le graphique nous montre que les zones industrielles présentent les concentrations les plus élevées suivies des zones résidentielles puis les zones mixtes et agricoles.

#Question 9:Ordinale × Ordinale : Tau de Kendall (ou Spearman) #La perception de la qualité de l'air est-elle liée à la gêne du bruit ?

#3. Analyse univariée

#Perception_air

```
table_percept_air_1a5 <- table(df$Perception_air_1a5)
```

```
table_percept_air_1a5
```


```
##
```

```
## 2 3 4 5
```


```
## 1 18 93 32
```

```
barplot(table_percept_air_1a5,
        main="Distribution de la perception de la qualité de l'air",
        ylab="Fréquence", xlab="La perception de la qualité de l'air")
```

Distribution de la perception de la qualité de l'air



```
#Gene du bruit
table_gene_bruit_1a5 <- table(df$Gene_bruit_1a5)
barplot(table_gene_bruit_1a5,
        main="Distribution des genes de bruit",
        ylab="Fréquence", xlab="Gene du bruit")
```



#3. Analyse bvariée

#Tableau de contingence

```
contingency_table <- table(df$Perception_air_1a5, df$Gene_bruit_1a5)
print(contingency_table)
```

```
##
##      1  2  3  4
##  2  0  0  0  1
##  3  0  7  7  4
##  4 17 50 21  5
##  5 13 10  8  1
```


#Graphique (barplot empilé)

```
ggplot(df, aes(x = Gene_bruit_1a5, fill = Perception_air_1a5)) +
  geom_bar(position = "fill") +
  labs(title = "Perception de la qualité de l'air selon la gene du bruit",
       x = "Gene_bruit_1a5",
       y = "Proportion") +
  theme_minimal() +
  scale_fill_brewer(palette = "Set1")
```

```
## Warning: The following aesthetics were dropped during statistical transformation: fill.
```

```
## i This can happen when ggplot fails to infer the correct grouping structure in
## the data.
```

```
## i Did you forget to specify a `group` aesthetic or to convert a numerical
## variable into a factor?
```



#4. Tests Statistiques

```
df$Perception_air_1a5 <- factor(
  df$Perception_air_1a5,
  levels = c("2", "3", "4", "5"),
  ordered = TRUE
)
df$Perception_air_1a5

## [1] 3 4 4 4 3 4 3 4 4 4 5 4 4 4 4 4 4 4 5 5 4 4 4 4 4 3 4 5 5 4 4 4
4 5 3
## [38] 4 4 4 4 4 4 4 5 4 4 5 3 4 4 4 3 4 4 5 4 4 4 5 4 3 4 3 5 4 5 5 4 4
5 3 3
## [75] 4 4 4 3 5 4 5 4 3 5 3 4 4 4 4 4 4 4 5 5 4 4 4 3 5 4 4 4 4 5 5 4 5 4
2 4 4
## [112] 4 4 4 4 4 5 4 5 4 4 3 4 4 4 4 3 4 4 4 4 3 4 5 4 4 4 5 5 4 4 5 5 5
## Levels: 2 < 3 < 4 < 5
```

#La p-value est inférieure à 0.05 donc il y'a pas de lien entre la perception de la qualité de l'air et la gene du bruit

```
df$Gene_bruit_1a5 <- factor(
  df$Gene_bruit_1a5,
  levels = c("1", "2", "3", "4"),
  ordered = TRUE
```



```

)
df$Gene_bruit_1a5

## [1] 4 2 3 4 2 3 2 2 2 1 2 2 4 2 2 2 2 2 3 1 1 2 2 1 3 2 2 3 3 3 3 2 1 1
2 2 4
## [38] 3 2 2 2 2 2 1 1 1 2 1 3 2 2 3 4 4 2 3 2 2 2 1 3 3 3 3 3 3 3 1 2 2
2 3 2
## [75] 3 3 2 3 3 2 1 1 2 2 4 3 2 2 2 2 2 3 1 1 1 1 3 2 4 2 3 2 1 1 1 1 1 1
4 3 3
## [112] 2 2 2 2 2 1 1 2 1 4 3 2 4 2 3 2 3 2 2 2 2 3 2 2 2 1 2 1 1 2 3 2 2
## Levels: 1 < 2 < 3 < 4

Percep <- as.numeric(df$Perception_air_1a5)
gene_bruit <- as.numeric(df$Gene_bruit_1a5)
#la Perception_air_1a5 et la Gene_bruit_1a5 sont des variables ordinales et les Observations sont indépendantes
#donc on peut faire le test de kendall
#test de kendall
#H0: il n'existe aucune association monotone entre X et Y.
#H1: il existe une association monotone

cor_kendall <- cor(Percep, gene_bruit, method = "kendall", use = "complete.obs")
#le taux de kendall est inférieur à 0.05 ,on rejette H0
# donc entre la Perception_air_1a5 et la Gene_bruit_1a5 il existe une association negative parfaite

print(cor_kendall)

## [1] -0.2708027

```

#Commentaire:ici on peut dire que plus le bruit est genant plus l'air est perçu comme mauvaise.

#Question 10: Données appariées : t apparié / Wilcoxon signé #La campagne a-t-elle réduit PM2.5 ?

```

library(dplyr)

df_poussiere <- df %>%
  filter(Campagne == "Campagne_poussiere")

df_apparie <- df_poussiere %>%
  filter(Phase_intervention %in% c("Avant", "Après")) %>%
  select(Station, Phase_intervention, PM25_ugm3) %>%
  tidyr::pivot_wider(names_from = Phase_intervention,
                    values_from = PM25_ugm3)

df_apparie

## # A tibble: 12 × 3
##   Station Avant Après

```

```
##      <fct>      <dbl> <dbl>
##  1 ST01        60.4 69.6
##  2 ST02        42.4 34.0
##  3 ST03        55.0 42.7
##  4 ST04        63.8 31.9
##  5 ST05        47.1 24.4
##  6 ST06        42.1 59.1
##  7 ST07        17.9  9.50
##  8 ST08        32.5 34.6
##  9 ST09        17.4  4
## 10 ST10        34.6 31.3
## 11 ST11        26.5 14.2
## 12 ST12        31.0  4
```

#Calculer les différences (Après / Avant)

```
df_apparie <- df_apparie %>%
  mutate(diff = Après - Avant)
df_apparie

## # A tibble: 12 × 4
##   Station Avant Après   diff
##   <fct>      <dbl> <dbl> <dbl>
##  1 ST01        60.4 69.6   9.27
##  2 ST02        42.4 34.0  -8.47
##  3 ST03        55.0 42.7 -12.2
##  4 ST04        63.8 31.9 -31.9
##  5 ST05        47.1 24.4 -22.7
##  6 ST06        42.1 59.1  17.0
##  7 ST07        17.9  9.50 -8.44
##  8 ST08        32.5 34.6   2.11
##  9 ST09        17.4  4    -13.4
## 10 ST10        34.6 31.3  -3.34
## 11 ST11        26.5 14.2 -12.3
## 12 ST12        31.0  4   -27.0
```

#Tester la normalité des différences (par station)

```
shapiro.test(df_apparie$diff)

##
##  Shapiro-Wilk normality test
##
## data:  df_apparie$diff
## W = 0.97359, p-value = 0.9445
```

#La normalite est verifiee car la p-value est superieur à 0.05

#Test apparié

```
t.test(df_apparie$Après, df_apparie$Avant, paired = TRUE)
```

```
##
## Paired t-test
##
## data: df_apparie$Après and df_apparie$Avant
## t = -2.2512, df = 11, p-value = 0.04579
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## -18.348858 -0.207046
## sample estimates:
## mean difference
## -9.277952

# On constate que :  $p < 0.05$  et  $\text{diff} < 0$ 
#Donc la campagne a réduit significativement les concentrations de PM2.5.
```